

Doğa Yağmur Yılmaz, Prof. Dr. S. Emre Alptekin

Département de Génie Industriel
Faculté d'Ingénierie et de Technologie, Université Galatasaray


SUJET

Le succès dans le secteur des services est largement déterminé par l'expérience utilisateur, ce qui met en lumière l'importance des systèmes de recommandation (RS) personnalisés offrant des suggestions adaptées aux besoins et aux demandes des utilisateurs pour améliorer leur satisfaction. Les RS établissent des liens entre les produits et/ou les utilisateurs offrant des recommandations en fonction des comportements ou des intérêts des utilisateurs, et contribuant ainsi à personnaliser l'expérience utilisateur. Ils se classent comme celui-ci :



```

graph TD
    A[Système de Recommandation] --> B[Filtrage Collaboratif]
    A --> C[Filtrage Basé sur le Contenu]
    A --> D[Systèmes Hybrides]
    B --> E[CF Basé Sur Utilisateur]
    B --> F[CF Basé Sur Élément]
    C --> G["-Analyse de Texte"]
    D --> H[ ]
    D --> I[ ]
    D --> J[ ]
    
```



OBJECTIF

Le projet ambitionne de concevoir un système de recommandation hybride exploitant les graphes pour surmonter les défis de la rareté des données et résoudre le problème du démarrage à froid, garantissant une expérience satisfaisante aux nouveaux utilisateurs.

Il vise à améliorer la précision de prédiction des préférences des utilisateurs en combinant l'apprentissage graphique, les techniques de réduction de dimension (UMAP et Autoencodeur), ainsi que les approches de filtrage collaboratif et basé sur le contenu utilisant des informations descriptives.

En se concentrant sur la construction de deux modèles distincts utilisant les techniques Autoencodeur et UMAP pour la réduction de dimension, le projet compare leurs performances et exploite efficacement les approches basées sur les graphes pour capturer les relations non-linéaires.

VALEUR ORIGINALE

Le projet adopte une approche graphique pour modéliser les relations entre les utilisateurs, combinée à la technique UMAP (Uniform Manifold Approximation and Projection), un algorithme d'apprentissage manifold, pour réduire les dimensions. Cette méthode permet de saisir les relations non linéaires dans les données en intégrant les caractéristiques descriptives de l'utilisateur.

METHODES ET TECHNOLOGIES



ARCHITECTURE DU MODELE




Figure d'Etape 1. Extraction des caractéristiques en utilisant le graphe de similarité et les informations catégorielles sur les utilisateurs




Figure d'Etape 2.1. Réduction de Dimension Avec UMAP

ou




Figure d'Etape 2.2. Réduction de Dimension Avec Autoencodeur




Figure d'Etape 3. Processus de clustering et estimation des évaluations basé sur les caractéristiques des utilisateurs et des éléments

COMPARAISON & RESULTATS

Critère	UMAP	Autoencodeur
Approche	Utilise les principes de l'apprentissage manifold, s'appuie sur la théorie des graphes et de la géométrie riemannienne.	Utilise une structure de réseau neuronal pour coder et décoder les données. Encodeur compresses les données d'entrée dans un espace latent de dimensions inférieures, et décodéur les reconstruit.
Complexité et flexibilité	Modèle plus simple.	Structure plus complexe et flexible.
Paramètres et temps de formation	Moins de paramètres à apprendre, fonctionne plus rapidement, mais peut prendre plus de temps à former avec de grands ensembles de données.	Plus de paramètres à apprendre, peut être plus lent à former avec de grands ensembles de données.
Efficacité et polyvalence	Adapté aux grands ensembles de données, souvent utilisé pour l'exploration de données, la visualisation et le regroupement.	Plus flexible et polyvalent, mais peut être plus lent avec de grands ensembles de données.
Préservation de la structure	Préserve à la fois la structure locale et globale des données. Les caractéristiques obtenues après la réduction de dimension reflètent mieux les caractéristiques originales des données.	Visé à capturer à la fois les détails fins et les structures plus larges des données. Représente les relations entre les points de données voisins en préservant la structure locale et globale des données.

```

Number of users in each cluster
sorted by cluster number:
0      109
1      297
2      1077
3      562
4      271
5      192
6      311
7      456
8      165
9      193
10     233
11     281
12     218
13     105
14      34
15     177
16     117
17     151
18      74
19     105
20     125
21     181
22     136
23      58
24      71
25     63
26      44
27      84
28      12

```

The best model was found at index #3
 Test MSE: 0.01577
 Average loss score across all folds: 0.02109

The best model was found at index #9
 Test MSE: 0.03126
 Average loss score across all folds: 0.03427

Meilleur Modèle d'UMAP



Meilleur Modèle d'AE



Dans les résultats obtenus avec Autoencodeur, l'erreur quadratique moyenne (RMSE) a été calculée comme étant de 0,933 et l'erreur absolue moyenne (MAE) a été calculée comme étant de 0,738. De même, le score R^2 a été déterminé à 0,302.

D'autre part, dans les processus de réduction de dimension et de regroupement utilisant la méthode UMAP, le RMSE a été calculé à 0,927, le MAE à 0,732, le score R^2 à 0,311.

CONCLUSION

Notre méthode de recommandation pour les systèmes utilisateurs et éléments offre une approche innovatrice pour résoudre le problème du démarrage à froid en exploitant les similarités entre les utilisateurs dans un graphe de similarité. En combinant ces informations avec des données secondaires sur les utilisateurs, nous avons pu améliorer la précision des recommandations. L'utilisation d'un autoencodeur pour extraire des caractéristiques à dimension réduite s'est avérée moins efficace que l'approche UMAP. Nos résultats démontrent que la réduction de dimension par UMAP est plus performante pour notre ensemble de données, soulignant ainsi son efficacité dans ce contexte spécifique.